



INSTITUTO FEDERAL DE EDUCAÇÃO, CIÊNCIA E
TECNOLOGIA BAIANO

Bacharelado em Sistemas de Informação

**UTILIZAÇÃO DE REDES NEURAIS NA
ANÁLISE E PREVISÃO DA TEMPERATURA
MÉDIA EM ITAPETINGA-BA**

Lucas Silva de Oliveira

Itapetinga - Bahia

23 de fevereiro de 2025

UTILIZAÇÃO DE REDES NEURAIS NA ANÁLISE E PREVISÃO DA TEMPERATURA MÉDIA EM ITAPETINGA-BA

Lucas Silva de Oliveira

Trabalho de Conclusão de Curso apresentado
como requisito parcial para obtenção do título
de Bacharel em Sistemas de Informação.

Orientador(a): Prof(a). Dr(a). Nome do(a)
Orientador(a).

Itapetinga - Bahia
23 de fevereiro de 2025

UTILIZAÇÃO DE REDES NEURAIS NA ANÁLISE E PREVISÃO DA TEMPERATURA MÉDIA EM ITAPETINGA-BA

Lucas Silva de Oliveira

Trabalho de Conclusão de Curso apresentado
como requisito parcial para obtenção do título
de Bacharel em Sistemas de Informação.

BANCA EXAMINADORA:

Prof(a). Dr(a). Nome do(a) Orientador(a) (Orientador(a))
IFBAIANO

Prof(a). Dr(a). Nome do(a) Avaliador(a)
Instituição

Prof(a). Dr(a). Nome do(a) Avaliador(a)
Instituição

Dedico este trabalho a...

Agradecimentos

Agradeço a...

"Coloca aqui a epígrafe."
— *Nome do autor da epígrafe*

Resumo

Aqui fica o resumo em português.

Palavras-chave: redes neurais, séries temporais, meteorologia.

Resumo

Aqui fica o resumo em inglês.

Keywords: neural networks, time series, meteorology.

Sumário

| | | |
|------------|---|-----------|
| 1 | INTRODUÇÃO | 1 |
| 1.1 | OBJETIVOS | 1 |
| 1.2 | OBJETIVOS ESPECÍFICOS | 1 |
| 1.3 | JUSTIFICATIVA | 1 |
| 1.4 | ORGANIZAÇÃO DOS CAPÍTULOS | 3 |
| 2 | FUNDAMENTAÇÃO TEÓRICA | 4 |
| 2.1 | Séries Temporais | 4 |
| 2.1.1 | Estacionariedade | 4 |
| 2.1.2 | Teste de Estacionariedade | 5 |
| 2.1.3 | Decomposição | 5 |
| 2.1.4 | Modelos | 5 |
| 2.1.4.1 | ARMA | 5 |
| 2.1.4.2 | ARIMA | 5 |
| 2.1.4.3 | SARIMA | 5 |
| 2.2 | Redes Neurais | 5 |
| 2.2.1 | Processo de Treinamento | 7 |
| 2.2.1.1 | Aprendizado Supervisionado e Não Supervisionado | 7 |
| 2.2.1.2 | Pre-Processamento dos Dados | 8 |
| 2.2.1.2.1 | Limpeza de Dados | 8 |
| 2.2.1.2.2 | Integração de Dados | 8 |
| 2.2.1.2.3 | Transformação de Dados | 9 |
| 2.2.1.2.4 | Redução de Dados | 9 |
| 2.2.1.3 | Overfitting e Underfitting | 9 |
| 2.2.1.4 | Técnicas de Validação | 10 |
| 2.2.1.4.1 | Hold-Out | 10 |
| 2.2.1.4.2 | K-Fold | 10 |
| 2.2.1.4.3 | Leave-One-Out | 10 |
| 2.2.1.4.4 | Bootstrap | 10 |
| 2.2.1.5 | Métricas de Avaliação | 10 |
| 2.2.2 | Multi Layer Perceptron | 11 |
| 3 | METODOLOGIA | 12 |
| 3.1 | Obtenção dos Dados | 12 |
| 3.2 | Preparação dos Dados | 12 |

| | | |
|-----|--|----|
| 3.3 | Desenvolvimento do Modelo de Rede Neural | 12 |
| 3.4 | Treinamento e Validação do Modelo | 12 |
| 3.5 | Avaliação e Análise dos Resultados | 12 |
| 4 | RESULTADOS ESPERADOS | 13 |
| 5 | CONSIDERAÇÕES FINAIS | 14 |
| | REFERÊNCIAS | 15 |

1 INTRODUÇÃO

Aqui é onde ficara a introdução da problemática

1.1 OBJETIVOS

Analisar e prever variações da temperatura média no município de Itapetinga-BA ao longo do tempo utilizando redes neurais artificiais.

1.2 OBJETIVOS ESPECÍFICOS

- Analisar séries temporais de temperatura média em Itapetinga-BA, utilizando redes neurais do tipo MLP.
- Identificar tendências de aquecimento e outros impactos ambientais, empregando um modelo de previsão baseado em aprendizado profundo.
- Avaliar o desempenho do modelo MLP considerando diferentes configurações, como número de camadas ocultas, neurônios por camada e funções de ativação.

1.3 JUSTIFICATIVA

Suspeita-se que as mudanças ambientais e climáticas tenham como principal responsável a ação humana, impulsionada pela intensa atividade industrial. A revolução industrial marcou o início dessa transformação, promovendo a adoção de novas fontes de energia e o fortalecimento do consumo de combustíveis fósseis, como o carvão mineral inicialmente e, posteriormente, o petróleo (MENDONÇA, 2006).

À vista disso, nas últimas décadas, os debates sobre as mudanças climáticas e a necessidade de uma sociedade mais consciente e participativa na preservação ambiental e no desenvolvimento sustentável se tornaram cada vez mais intensos. Em 1972, ao identificar a vulnerabilidade do planeta Terra, houve um esforço mundial conjunto em entender os problemas ambientais e ponderar medidas para prevenir e amenizar determinadas crises.

A Conferência das Nações Unidas para o Meio Ambiente Humano, também conhecida como Conferência de Estocolmo, realizada em 1972 na cidade de Estocolmo, na Suécia, foi um marco histórico por ser a primeira conferência global com foco no meio ambiente. Durante o evento, deu-se início à estruturação de mecanismos de proteção ambiental, que foram ampliados na Segunda Conferência das Nações Unidas sobre o Meio Ambiente e Desenvolvimento, realizada em 1992, conhecida como Rio-92. Nessas conferências, foram

estabelecidos diversos acordos para a proteção do meio ambiente, da biodiversidade e de outros aspectos relacionados à sustentabilidade, como a Agenda 21 (PASSOS, 2009).

Entretanto, de acordo com relatório especial publicado em 2020 pelo Painel Intergovernamental sobre Mudanças Climáticas (IPCC), desde o período pré-industrial, a temperatura média do ar na superfície da Terra quase dobrou em relação à média global registrada anteriormente. Além disso, estima-se que 23% das emissões antrópicas de gases de efeito estufa sejam provenientes de atividades relacionadas à agricultura, silvicultura e outras práticas agrícolas.

No Brasil, em 2019, logo após a transição para a nova gestão federal, as invasões às terras indígenas por grupos ilegais, como garimpeiros, foram retomadas. Como resultado, a taxa de desmatamento em junho daquele ano já apresentava um aumento alarmante de 60% em relação ao mesmo mês do ano anterior. Além disso, houve uma intensificação de atividades ilícitas, como a grilagem de terras, mineração clandestina e exploração madeireira na Amazônia (FILHO, 2020).

Filho (2020) afirma que esse aumento foi impulsionado por questionamentos feitos pelas autoridades governamentais naquele momento, que duvidavam da veracidade das informações fornecidas pelos órgãos responsáveis pelo monitoramento ambiental. Além disso, declarações sobre a possível flexibilização da regulamentação ambiental reforçaram, entre certos grupos, a percepção de uma "liberação total". Isso resultou na intensificação de práticas prejudiciais ao meio ambiente, à saúde pública e ao tecido social.

Segundo dados do MapBiomass, o Brasil já havia perdido cerca de 20% de suas áreas naturais até 1985. Entre 1985 e 2023, essa perda se intensificou, aumentando em mais 13%, atingindo um total de 33% do território nacional. A velocidade alarmante dessa transformação na cobertura e no uso do solo contribui significativamente para o agravamento dos riscos climáticos no país. No ano de 2023, a Bahia se destacou como o segundo estado com maior taxa de desmatamento. Em comparação com 2022, houve um aumento de 27% na área desmatada, sendo o Cerrado o bioma mais afetado, respondendo por 67% do total. Na sequência, aparecem a Caatinga e a Mata Atlântica como os biomas mais impactados pelo desmatamento no estado (POLCRI, 2024).

Dessa forma, torna-se fundamental dispor de instrumentos capazes de prever eventos climáticos com baixa margem de erro e antecedência suficiente para viabilizar a construção de soluções e estratégias eficazes na mitigação de danos. Nesse contexto, destacam-se os modelos de *machine learning*, que, ao utilizar dados históricos meteorológicos, podem realizar previsões mais assertivas e robustas.

Nesse sentido, este trabalho tem como foco analisar as mudanças na temperatura média no município de Itapetinga-BA, cidade historicamente conhecida como a 'Capital da Pecuária'. Além de contar com um setor industrial significativo, Itapetinga abriga um campus avançado da Universidade Estadual do Sudoeste da Bahia e um campus do Instituto Federal Baiano, consolidando-se como um importante polo educacional e

econômico na região.

1.4 ORGANIZAÇÃO DOS CAPÍTULOS

Este trabalho está dividido da seguinte forma: No capítulo 2, é apresentado uma visão geral dos conceitos teóricos que fundamentam este projeto, como séries temporais, suas características e modelos de previsão. Além disso, é introduzido o conceito de redes neurais, abordando seus componentes, aprendizado, métricas e a arquitetura utilizada neste trabalho. O capítulo 3 detalha os métodos e técnicas utilizados na pesquisa. No capítulo 4, são mostrados os resultados obtidos. Por fim, no capítulo 5, são apresentamos as considerações finais, destacando as principais contribuições do trabalho e propondo direções para futuras pesquisas.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo, são apresentados os principais conceitos e fundamentos necessários para a compreensão, entendimento e progresso deste trabalho.

2.1 Séries Temporais

Muitas pessoas, em algum momento, já imaginaram como seria prever o futuro e ter acesso a informações sobre eventos ou situações de suas vidas. Essa curiosidade reflete um desejo universal, mas também uma necessidade presente em diversas áreas, como na gestão governamental, no setor financeiro e em contextos sociais. Nesse cenário, surge o conceito de Série Temporal, definido como um conjunto de observações organizadas sequencialmente no tempo, representadas por x_t , com cada valor correspondente a um instante específico t (BOX et al., 2015). O estudo de Séries Temporais permite não apenas compreender as características de fenômenos que evoluem ao longo do tempo, mas também desenvolver e ajustar modelos estatísticos capazes de explicar ou prever o comportamento dos dados observados.

De acordo com Brockwell e Davis (2002), séries temporais podem ser classificadas discretas e contínuas, uma série temporal é discreta quando o conjunto t_0 de tempos em que as observações são feitas é um conjunto discreto, como o caso de observações que são realizadas em um determinado intervalo de tempo fixo. Sendo representada por:

$$T = \{t_1, \dots, t_n\}, \quad \{X_t : t \in T\} \quad (2.1)$$

E séries temporais contínuas quando suas observações são obtidas continuamente no tempo. Sendo expressa por:

$$T = [t_1, t_2], \quad \{X(t) : t \in T\} \quad (2.2)$$

2.1.1 Estacionariedade

A estacionariedade refere-se ao comportamento dos valores de uma série temporal ao longo do tempo. Uma série é classificada como estacionária quando seus dados flutuam de maneira aleatória em torno de uma média fixa, mantendo-se em um estado de equilíbrio ao longo do período analisado. Contudo, na prática, muitas séries temporais do cotidiano não apresentam essa característica, exibindo tendências, sazonalidades ou outras formas de variação que indicam a presença de não estacionariedade (MORETTIN; TOLOI, 2018).

2.1.2 Teste de Estacionariedade

2.1.3 Decomposição

Costa (2019) destaca que ao iniciar a análise de uma série temporal é de alta valia utilizar de gráficos criados sequencialmente no tempo, visto que isso pode revelar determinados padrões de comportamento e algumas características que podem estar presentes nos dados, como tendência, sazonalidade, ciclicidade e ruído, também conhecido como erro aleatório.

A tendência (μ_t) representa o padrão de variação de uma grandeza ao longo do tempo. Em termos gerais, ela indica se uma série temporal segue um crescimento ou um declínio de forma consistente. Séries temporais que exibem esse comportamento são classificadas como não estacionárias.

A ciclicidade (ψ_t) refere-se a variações nos dados que ocorrem em intervalos regulares, com uma duração superior a um ano. Esses ciclos podem estar associados a fatores econômicos, políticos ou sociais, manifestando-se de forma recorrente ao longo do tempo.

A sazonalidade (γ_t) é uma variação periódica que se repete em intervalos regulares, mantendo a mesma frequência e intensidade, ocorrendo em um intervalo de tempo menor que um ano. Esse comportamento pode ser observado em vendas durante datas comemorativas anuais, como Páscoa, Natal e São João, além de em padrões climáticos.

O ruído (ϵ_t) representa a variabilidade imprevisível em uma série temporal, correspondendo a flutuações que não podem ser explicadas por outros componentes. Além disso, ele atua como uma fonte de erro nas previsões, afetando a precisão dos modelos.

2.1.4 Modelos

2.1.4.1 ARMA

2.1.4.2 ARIMA


2.1.4.3 SARIMA

2.2 Redes Neurais

Com o avanço dos estudos sobre o funcionamento do cérebro humano. Analisando o cérebro, percebeu-se a constituição complexa, não linear e paralela dele, sendo composto por 10 bilhões de neurônios. Cada neurônio conectado, em média, a outros 10 bilhões de neurônios, formando uma vasta e sofisticada rede (HAYKIN, 2009).

Em uma rede neural, a comunicação é realizada através de sinais eletroquímicos, e esses sinais são transmitidos e processados através dos componentes presentes em sua estrutura. Os componentes presentes na estrutura de um neurônio são exibidos na Figura 1:

Figura 1 – Neurônio Biológico.



Fonte: The University Of Queensland.

- **Corpo Celular ou Soma:** responsável por integrar os sinais recebidos de outros neurônios;
- **Dendritos:** responsáveis por receber informações transmitidas por outros neurônios. São consideradas as zonas receptivas;
- **Axônio:** responsável por transmitir as informações para outros neurônio também chamado de linha de transmissão;

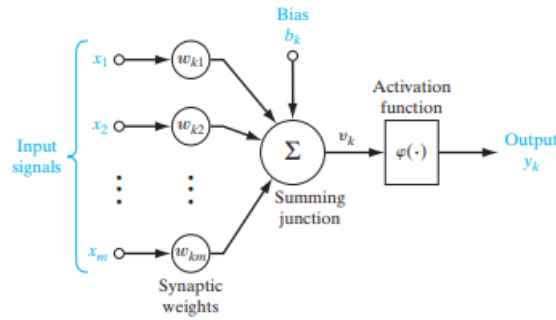
Quando o conjunto de sinais recebidos é suficientemente forte para ativar o neurônio, este gera um impulso elétrico que percorre seu axônio. Esse sinal eletroquímico coordena e organiza a atividade neuronal, permitindo ao cérebro realizar diversas formas de processamento de maneira extremamente eficiente, muitas vezes mais rápida do que os computadores digitais convencionais (HAYKIN, 2009). Ao entender de que forma o cérebro humano processa informações, cientistas buscaram reproduzir seu funcionamento de forma artificial.

Com isso, surgiram as Redes Neurais Artificiais (RNA's), que tenta mimetizar o sistema nervoso humano, RNA's são capazes de assimilar e reter conhecimento, possuindo um alto grau de paralelismo e extremamente conectada. As RNA's são utilizadas para desempenhar a mesma função após o treinamento. Sendo seu elemento constituinte chamado de neurônio artificial (ULINICK; SCHASTAI, 2019).

De acordo com Haykin (2009), um neurônio é uma unidade de processamento de informação que é fundamental para a operação de uma rede neural. Na Figura 2 é ilustrado os componentes básicos da arquitetura mais simples de uma rede neural.

- **Camada de Entrada:** Responsável por receber as informações do ambiente externo e transmiti-las ao restante da rede para processamento.

Figura 2 – Neurônio Artificial (Perceptron).



Fonte: Haykin (2009).

- **Sinapses:** Representam as conexões entre os neurônios, simuladas por pesos w_1, w_2, \dots, w_n , que determinam se o sinal terá um efeito estimulante (excitador) ou inibidor.
- **Bias:** É um valor adicional que ajusta a ativação do neurônio, permitindo que ele se "ajuste" de forma mais flexível. O viés pode ser positivo ou negativo e ajuda a rede a decidir quando ativar ou não o neurônio, independentemente das entradas. Ele atua como uma espécie de "ajuste fino", permitindo que a rede aprenda melhor a partir dos dados.
- **Somador:** Mecanismo que agrega todas as entradas, considerando seus respectivos pesos, para gerar um valor combinado.
- **Função de ativação:** Limita a amplitude do sinal de saída a um intervalo finito, determinando se o neurônio será ativado com base na soma ponderada das entradas.
- **Camada de Saída:** Fornece o resultado final do processamento do neurônio, representando a resposta da rede ao estímulo recebido.

2.2.1 Processo de Treinamento

Sistemas de aprendizado de máquina podem ser categorizados de acordo com o tipo de treinamento que eles recebem. O aprendizado supervisionado ocorre quando o modelo é treinado por meio de exemplos explícitos. Em contrapartida, no aprendizado não supervisionado, não há a definição de exemplos explícitos para orientar o modelo. Além disso, existem diversas boas práticas para garantir que o modelo consiga realizar um bom aprendizado e métricas para avaliá-lo.

2.2.1.1 Aprendizado Supervisionado e Não Supervisionado

No aprendizado supervisionado, o modelo é treinado com pares de dados (x, y) , onde x representa os dados de entrada e y o valor esperado (ou rótulo). Durante o treinamento, o

modelo compara as previsões feitas com os valores reais utilizando uma função de perda, que mede o erro. Em seguida, seus parâmetros são ajustados iterativamente, geralmente por meio de métodos como o gradiente descendente, para minimizar esse erro e melhorar a precisão das previsões.

No aprendizado não supervisionado, o modelo não recebe o par de dados (x, y) , mas apenas as entradas x . A partir disso, ele busca identificar padrões, estruturas ou associações presentes nos dados, ajustando os pesos de acordo com o objetivo do método utilizado.

2.2.1.2 Pre-Processamento dos Dados

Antes de treinar um modelo com algoritmos de aprendizado de máquina, é imprescindível realizar o pré-processamento dos dados. Esse processo assegura que os dados estejam padronizados, consistentes e adequados, permitindo que os modelos alcancem um desempenho superior e resultados confiáveis nas métricas de avaliação. Para isso, são utilizadas técnicas que evitam problemas como dados ausentes, inconsistências, valores conflitantes e incongruentes. Essas técnicas são geralmente divididas em quatro categorias principais: limpeza, integração, transformação e redução de dados (SILVA, 2021; OLIVEIRA, 2024).

2.2.1.2.1 Limpeza de Dados

Um problema comum em conjuntos de dados (*datasets*) é a presença de valores faltantes (ou nulos), que podem ocorrer devido a diferentes fatores. Esses fatores incluem registros manuais realizados de forma inadequada, falhas em sistemas de extração, transformação e carregamento de dados (*ETL*) ou até mesmo problemas em sensores de dispositivos autônomos. A presença de valores faltantes compromete tanto a qualidade dos dados quanto o desempenho do treinamento de modelos de *machine learning*, caso não seja tratada adequadamente. Sivakumar e Gunasundari (2017) apresentam algumas abordagens eficazes para lidar com essa problemática, como:

- Exclusão de linhas do *dataset* que contenham valores faltantes.
- Preenchimento dos valores ausentes utilizando métricas estatísticas, como a média ou mediana, para gerar estimativas aproximadas que mantenham a coerência do conjunto de dados.

2.2.1.2.2 Integração de Dados

É o processo de combinar dados provenientes de diversas fontes, ecossistemas e tecnologias, de maneira adequada e coerente. Durante esse processo de integração, podem surgir problemas, como inconsistências nos dados e redundâncias no conjunto de dados gerado (SIVAKUMAR; GUNASUNDARI, 2017; SILVA, 2021; OLIVEIRA, 2024).

2.2.1.2.3 Transformação de Dados

Nesse estágio, os dados são transformados em formatos adequados para utilização no modelo. Sivakumar e Gunasundari (2017) e Oliveira (2024) definem algumas atividades executadas nesta etapa:

- Uso de normalização para ajustar os valores dos dados a uma escala comum, permitindo fácil comparação entre diferentes atributos.
- Eliminação de ruídos com técnicas de suavização.
- Aplicação de técnicas de agregação para resumir dados complexos e detalhados.
- Generalização de valores específicos em categorias mais amplas, como, por exemplo, a generalização de faixas etárias.

2.2.1.2.4 Redução de Dados

Nessa etapa, são utilizadas metodos para reduzir o volume de dados que serão analisados, visando maior velocidade de processamento e melhora na eficiência do processo, mas sem comprometer a qualidade e integridade dos dados originais. Sivakumar e Gunasundari (2017) indicam algumas estratégias, sendo elas:

- Redução de dimensionalidade do *dataset*, removendo atributos que não melhoram a performance do modelo.
- Utilização de operações de agregação de dados para resumo de informações.
- Utilização de técnicas de *encoding* para compactação de dados.

2.2.1.3 Overfitting e Underfitting

Ao construir modelos de redes neurais, diversos desafios podem surgir, sendo dois dos mais comuns o *Overfitting* e o *Underfitting*. O *Overfitting* ocorre quando o modelo aprende tão bem os padrões dos dados de treinamento que sua capacidade de generalização para novos dados é comprometida. Isso acontece porque o modelo não apenas captura as características relevantes dos dados, mas também absorve ruídos e padrões específicos do conjunto de treinamento (Montesinos-LÓPEZ; Montesinos; Crossa, 2022). Como consequência, ao ser exposto a novos exemplos, seja do conjunto de teste ou de outros conjuntos de dados inéditos, o modelo tende a aplicar regras memorizadas, em vez de identificar padrões generalizáveis. Isso compromete sua capacidade de inferir corretamente a partir de dados não vistos, resultando em um desempenho insatisfatório.

Por outro lado, o *Underfitting* ocorre quando o modelo é excessivamente simples, muitas vezes devido à utilização de poucas variáveis de entrada. Isso impede que o

modelo represente adequadamente os padrões predominantes no *dataset* e capture as características essenciais das amostras, resultando em um desempenho insatisfatório já durante o treinamento. Além disso, esse problema também pode surgir quando o conjunto de dados de treinamento é muito pequeno ou pouco representativo da população, comprometendo ainda mais a capacidade de aprendizagem do modelo (Montesinos-LÓPEZ; Montesinos; Crossa, 2022).

2.2.1.4 Técnicas de Validação

A validação é uma etapa crucial para avaliar a capacidade preditiva de um modelo de *machine learning*, além de ser fundamental para o ajuste de seus hiperparâmetros.

2.2.1.4.1 Hold-Out

É uma técnica simples de validação de modelos de *machine learning*, ela consiste em dividir o conjunto de dados em duas partes: uma para treino e outra para validação. Ou seja, parte dos dados é usada para treinar o modelo e a outra para testar a capacidade de previsão do modelo. Dado um conjunto de dados d , um subconjunto p é extraído dos dados, formando a amostra de treino d_t onde $t = n * (1 - p)$ e amostra de validação d_v com tamanho $v = n * p$. A técnica é muito simples, vide que divide os dados entre treino e validação, dessa forma, ele usa apenas uma parte dos dados para treinar o modelo. Dessa maneira, o modelo pode não generalizar bem para os dados não vistos presentes no conjunto de validação, acarretando um erro de previsão maior (CUNHA, 2019).

2.2.1.4.2 K-Fold

2.2.1.4.3 Leave-One-Out

2.2.1.4.4 Bootstrap

2.2.1.5 Métricas de Avaliação

Vide que a utilização de modelos de *machine learning* é com o foco de prever determinados eventos através de métodos estáticos e probabilísticos. A exatidão da previsão é o fator crucial em avaliar a qualidade de um modelo. Sousa (2011) apresenta a Tabela 1 com as métricas mais comuns para avaliar as previsões dos modelos.

Tabela 1 – Métricas de Avaliação

| Designação | Fórmula |
|---------------------------------------|---|
| Erro Absoluto Médio (MAE) | $\frac{1}{n} \sum_{t=1}^n e_t $ |
| Erro Quadrático Médio (MSE) | $\frac{1}{n} \sum_{t=1}^n (e_t)^2$ |
| Raiz do Erro Quadrático Médio (RMSE) | $\sqrt{\frac{1}{n} \sum_{t=1}^n (e_t)^2}$ |
| Erro Percentual Absoluto Médio (MAPE) | $\frac{1}{n} \sum_{t=1}^n \left(\frac{ e_t }{ y_t } \right) 100$ |

Fonte: Sousa (2011)

2.2.2 Multi Layer Perceptron

O algoritmo de backpropagation ajusta os pesos da rede neural para reduzir o erro entre a saída prevista e o valor esperado. O erro é calculado e propagado pelas camadas até atingir um nível mínimo aceitável (MARANGONI, 2010).

Grus (2021) apresenta o funcionamento padrão do treinamento de uma rede neural utilizando o algoritmo de backpropagation como método de ajuste dos pesos. Considera-se que a rede possui n , os quais são ajustados de acordo com o seguinte procedimento:

1. Realiza-se o feed-forward, em que as entradas são processadas para produzir as saídas de todos os neurônios;
2. Como o algoritmo é supervisionado, os valores esperados das saídas são conhecidos. Assim, calcula-se uma função de perda, geralmente definida como a soma dos erros quadráticos entre as saídas reais e as esperadas;
3. O gradiente dessa função de perda é calculado em relação aos pesos dos neurônios de saída;
4. Os gradientes e os erros são propagados para trás com o objetivo de calcular os gradientes associados aos pesos dos neurônios ocultos;
5. Atualizam-se os pesos aplicando um passo em direção ao gradiente descendente, controlado por um parâmetro denominado learning rate (taxa de aprendizagem).

3 METODOLOGIA

No decorrer deste capítulo são abordados ambiente e metodologia utilizada durante o desenvolvimento do presente trabalho.

3.1 Obtenção dos Dados

Para a aplicação de modelos de previsão, é essencial dispor de uma quantidade significativa de dados para o treinamento, validação e teste do modelo, bem como para a inferência dessas informações sobre a população como um todo. No Brasil, o Instituto Nacional de Meteorologia (INMET) é o órgão responsável pelo Banco de Dados Meteorológicos (BDMEP), planejado para coletar, armazenar, processar e disponibilizar dados e informações sobre variáveis meteorológicas.

Esses dados podem ser gerados localmente, por meio de estações meteorológicas convencionais ou automáticas, ou captados remotamente, utilizando sensores orbitais, radares, entre outros dispositivos (VIANNA et al., 2017). O Banco de Dados Meteorológicos para Ensino e Pesquisa (BDMEP), em particular, reúne informações meteorológicas diárias provenientes das estações da rede do INMET, seguindo as normas técnicas da Organização Meteorológica Mundial (INMET, s.d.).

3.2 Preparação dos Dados

3.3 Desenvolvimento do Modelo de Rede Neural

3.4 Treinamento e Validação do Modelo

3.5 Avaliação e Análise dos Resultados

4 RESULTADOS ESPERADOS

5 CONSIDERAÇÕES FINAIS

Referências

- BOX, G. E. P. et al. *Time Series Analysis: Forecasting and Control*. 5th. ed. Hoboken, NJ: John Wiley & Sons, 2015.
- BROCKWELL, P. J.; DAVIS, R. A. *Introduction to Time Series and Forecasting*. Second. [S.l.]: Springer, 2002.
- CLIMÁTICAS, P. I. sobre M. *Mudança do clima e terra: sumário para formuladores de políticas*. Brasília: Ministério da Ciência, Tecnologia, Inovações e Comunicações (MCTI), 2020. Relatório especial sobre mudança do clima, desertificação, degradação da terra, manejo sustentável da terra, segurança alimentar e fluxos de gases de efeito estufa em ecossistemas terrestres. ISBN 978-92-9169-154-8. Disponível em: <<https://repositorio.mcti.gov.br/handle/mctic/5301>>.
- COSTA, E. S. d. *Análise da Série Temporal de Precipitação Total Mensal do Município de Cruz das Almas-BA*. Brasil: [s.n.], 2019. Trabalho monográfico apresentado para obtenção do grau de bacharel em Ciências Exatas e Tecnológicas.
- CUNHA, J. P. Z. *Um estudo comparativo das técnicas de validação cruzada aplicadas a modelos mistos*. Dissertação (Dissertação (Mestrado em Estatística)) — Instituto de Matemática e Estatística, Universidade de São Paulo, São Paulo, 2019. Acesso em: 2025-02-23.
- FILHO, H. B. Bolsonaro, meio ambiente, povos e terras indígenas e de comunidades tradicionais: Uma visada a partir da amazônia. *Cadernos de Campo (São Paulo - 1991)*, v. 29, p. e178663, 12 2020.
- GRUS, J. *Data Science do Zero: Noções Fundamentais com Python*. 2. ed. Rio de Janeiro, Brasil: Alta Books, 2021. 416 p. ISBN 978-8550811765.
- HAYKIN, S. *Neural Networks and Learning Machines*. Third. Upper Saddle River, NJ: Pearson Education, 2009.
- MARANGONI, P. H. *Redes Neurais Artificiais para Previsão de Séries Temporais no Mercado Acionário*. Florianópolis: Universidade Federal de Santa Catarina - UFSC, 2010. Trabalho de Conclusão de Curso (Graduação em Ciências Econômicas).
- MENDONÇA, F. Aquecimento global e suas manifestações regionais e locais: alguns indicadores da região sul do brasil. *Revista Brasileira de Climatologia*, v. 2, 2006.
- Montesinos-LÓPEZ, O.; Montesinos, A.; Crossa, J. *Overfitting, Model Tuning, and Evaluation of Prediction Performance*. [S.l.: s.n.], 2022. 109-139 p. ISBN 978-3-030-89009-4.
- MORETTIN, P. A.; TOLOI, C. M. C. *Análise de Séries Temporais: Modelos Lineares Univariados (Volume 1)*. 3. ed. São Paulo: Blucher, 2018. 474 p. ISBN 978-8521213512.
- OLIVEIRA, J. V. de. *Análise comparativa de algoritmos de aprendizado de máquina aplicados ao Campeonato Brasileiro de Futebol*. 2024. Trabalho de Conclusão de Curso (TCC).

PASSOS, P. N. Calmon de. A conferência de estocolmo como ponto de partida para a proteção internacional do meio ambiente. *Revista Direitos Fundamentais & Democracia*, v. 6, n. 6, 2009. Disponível em: <<https://revistaeletronicardfd.unibrasil.com.br/index.php/rdfd/article/view/18>>.

POLCRI, M. *Bahia desmata área equivalente a 737 campos de futebol por dia: o estado ocupa a segunda posição no ranking nacional, atrás apenas do Maranhão*. 2024. Disponível em: <<https://www.correio24horas.com.br/minha-bahia/bahia-desmata-area-equivalente-a-737-campos-de-futebol-por-dia-0624>>.

SILVA, D. F. B. F. d. *Pré-processamento de Dados e Comparação entre Algoritmos de Machine Learning para a Análise Preditiva de Falhas em Linhas de Produção para o Controlo*. Tese (Doutorado) — Instituto Superior de Engenharia do Porto, 2021.

SIVAKUMAR, A.; GUNASUNDARI, R. A survey on data preprocessing techniques for bioinformatics and web usage mining. *International Journal of Pure and Applied Mathematics*, v. 117, n. 20, 2017.

SOUSA, J. A. V. *Aplicação de Redes Neurais na Previsão de Vendas para Retalho*. Dissertação (Dissertação de Mestrado) — Faculdade de Engenharia da Universidade do Porto (FEUP), Porto, Portugal, 2011. Orientador na FEUP: Eng^o. Eduardo José Rego Gil Costa; Orientador no INESC Porto: Eng^o. Rui Diogo Rebelo.

ULINICK, A. A. de Q.; SCHASTAI, B. *Previsão de demanda para controle de estoque: aplicação de redes neurais artificiais em séries temporais*. 2019. 58 p. Trabalho de Conclusão de Curso (Bacharelado em Engenharia Elétrica) – Universidade Tecnológica Federal do Paraná, Ponta Grossa.

VIANNA, L. F. d. N. et al. Bancos de dados meteorológicos: Análise dos metadados das estações meteorológicas no estado de santa catarina, brasil. *Revista Brasileira de Meteorologia*, v. 32, n. 1, p. 53–64, jan 2017.